

Document Quality Scoring - Nihai Teknik Rapor

Document Quality Scoring — Nihai Teknik Rapor

Tarih: 17 Ağustos 2026 **Kapsam:** Literatür taraması + Blur, Glare, Darkness, Skew, Occlusion modüllerinin baseline geliştirmesi ve deneysel değerlendirmesi.

Okuma notu — üç bilgi türü: Bu rapor boyunca üç farklı bilgi türü açıkça ayrıştırılmıştır: - **Literatür** — daha önce başkaları tarafından yapılmış, yayınlanmış çalışmalar. - **Bizim Yöntemimiz** — bu projede seçip uyguladığımız yöntem. - **Bizim Sonuçlarımız** — bu projede yaptığımız deneylerden elde edilen, ölçülmüş sonuçlar.

Deneysel olarak ölçülmemiş hiçbir değer kesin bir sonuç gibi sunulmamıştır; bu durumlarda **“Not evaluated”** veya **“N/A”** ibaresi kullanılmıştır. Rapor, yalnızca `project_notes.md`, `research/` klasörü, gerçekleştirilen deneyler ve bunların `results/` klasöründeki çıktılarına dayanmaktadır.

1. Abstract

Bu proje, akıllı telefonla çekilmiş belge/kimlik görüntülerindeki beş temel kalite problemini — **blur (bulanıklık), glare (parlama), darkness (yetersiz aydınlatma), skew (eğiklik) ve occlusion (kapanma)** — ayrı ayrı ölçüp, ileride açıklanabilir tek bir **Document Quality Score (0-100)**'a birleştirmeyi hedefleyen bir sistemin ilk (baseline) aşamasını kapsar. Beş modülün her biri için literatürde önerilen klasik (training-free) yöntemler uygulanmış, sentetik ama kontrollü (yer gerçeği bilinen) veriler üzerinde deneysel olarak test edilmiştir. Sonuçlar karışıktır ve bu raporun en değerli bulgularından biri tam olarak budur: **Blur, Darkness ve Occlusion modüllerinde seçilen baseline yöntemler beklendiği gibi güçlü, ölçülebilir sinyaller üretirken, Glare modülünde seçilen baseline yöntem sentetik (gri tonlamalı) veri üzerinde etkisiz bulunmuş, Skew modülünde ise iki yöntemden biri (Projection Profile) belirli koşullarda (az metin yoğunluğu) ciddi biçimde başarısız olmuştur.** Bu proje, henüz feature-fusion / ML skorumaya aşamasına (Aşama 5) geçmemiştir; nihai 0-100 skor bu raporun kapsamı dışındadır ve “Not evaluated” olarak işaretlenmiştir. Rapor ayrıca, projenin asıl motivasyonu olan **kimlik belgesi sahteciliği tespiti** için, bu beş kalite modülünün ötesinde, literatürden derlenen ve daha az bilinen adli (forensic) yöntemler hakkında gerekçeli öneriler sunmaktadır (bkz. Bölüm 20).

2. Introduction

Kimlik doğrulama, belge işleme ve OCR sistemlerinin güvenilirliği, girdi olarak aldıkları görüntünün kalitesine doğrudan bağlıdır. Düşük kaliteli bir görüntü (bulanık, parlamalı, karanlık, eğik veya kısmen kapalı), aşağı akış (downstream) sistemlerinde hem yanlış kabul hem yanlış red hatalarına yol açabilir. Bu proje, böyle bir kalite değerlendirme sisteminin ilk aşamasını — beş temel bozulma türünün ayrı ayrı, açıklanabilir biçimde ölçülmesini — ele almaktadır.

Projenin nihai motivasyonu, yalnızca genel bir görüntü kalitesi ölçer inşa etmek değil, **kimlik belgesi sahteciliğinde kullanılan/gizlenen bozulmaları**, doğrudan “kara kutu” bir CNN yerine, daha yüksek doğruluk sağlayan, uygulanabilir ve gerekçelendirilebilir yöntemlerle tespit edebilmektir. Bu rapor, bu hedefe giden yolun ilk adımını — capture-quality (çekim kalitesi) değerlendirmesini — belgelemektedir; asıl sahtecilik tespiti (tamper detection) için önerilen ek yöntemler Bölüm 20’de ayrıca ele alınmıştır.

3. Problem Definition

Akıllı telefonla çekilen belge görüntülerinde kamera açısı, odaklama, hareket, aydınlatma ve fiziksel

engeller nedeniyle beş temel bozulma oluşabilir:

Problem	Temel soru
Blur	Görüntü ne kadar bulanık?
Glare	Hangi bölgeler aşırı yansıma nedeniyle kullanılamıyor?
Darkness	Görüntü/bölgeler ne kadar yetersiz aydınlatılmış?
Skew	Belge kaç derece eğik?
Occlusion	Belgenin hangi bölgesi, ne önemde kapalı?

(Kaynak: `initial_research.md` — proje başlangıç dokümanı.)

Bu beş problem birbirinden farklı fiziksel nedenlere ve farklı en-doğal ölçüm türlerine sahip olduğu için, tek bir algoritma yerine **problem-bazlı yöntem seçimi** tercih edilmiştir.

4. Related Work / Literature Review

Tam literatür taraması `research/literature_review.md` ve `research/references.md` dosyalarındadır; burada özet sunulmaktadır.

Literatür: Bu alan **Document Image Quality Assessment (DIQA)** olarak adlandırılır (Alaei, Bui, Doermann & Pal, 2023 — ACM Computing Surveys survey’i). **SmartDoc-QA** (Nayef et al., 2015, CBDAR), belge kalitesini OCR doğruluğu üzerinden değerlendiren önemli bir benchmark’tır. Her problem için literatürde önerilen klasik ve ileri yöntemler:

Problem	Klasik yöntemler (literatür)	Öğrenme tabanlı yöntemler (literatür)
Blur	Laplacian, Gradient/Tenengrad, FFT	CNN, SVR + el yapımı özellikler
Glare	HSV, luminance, connected components	CNN segmentation (Rodin & Orlov, 2019)
Darkness	Brightness, histogram, percentile	Illumination estimation (Wang et al., 2025 survey)
Skew	Hough, Projection Profile	CNN angle regression
Occlusion	OCR/Layout	Detection/Segmentation

(Bu tablo, `initial_research.md`’de zaten sunulmuş ve bu oturumda literatürle çapraz kontrol edilmiş bir özetir — bkz. `research/references.md` doğrulama durumları.)

2025-2026 döneminde alanın MLLM (multimodal büyük dil modeli) tabanlı yaklaşımlara (DeQA-Doc, Q-Doc — bkz. `research/literature_review.md` Bölüm 3) doğru genişlediği de bu oturumda ayrıca tespit edilmiştir; bu yaklaşımlar bu projede uygulanmamıştır.

5. Dataset

Literatür: SmartDoc-QA (~13.7 GB, CBDAR 2015), gerçek smartphone ile çekilmiş belge görüntüleri içerir ve OCR tabanlı ground truth sağlar. Kimlik belgesi odaklı ek veri setleri (MIDV-500, MIDV-2020, IDNet) `research/literature_review.md` Bölüm 4.2’de listelenmiştir.

Bizim Yöntemimiz: Bu projede **hiçbir gerçek/dış veri seti henüz indirilip kullanılmamıştır**. Bunun yerine, tüm deneyler **sentetik olarak üretilen belge görüntüleri** üzerinde yapılmıştır

(`experiments/_common/synthetic_documents.py`):

- 850×1100 piksel, beyaz zemin, siyah metin.
- Başlık + 3 mock kimlik alanı (Ad Soyad, Belge No — 10 haneli, Tarih) + gövde paragrafları (rastgele Türkçe kelime havuzundan).
- 12 belgelik sabit bir ızgara: 3 font boyutu (14/20/28px) × 2 paragraf yoğunluğu (2/5) × 2 tekrar.
- Her modül için, bu 12 belgeye bilinen (yer gerçeği) şiddette kontrollü bozulmalar (Gaussian blur,

sentetik glare lekesi, çarpımsal karartma, döndürme, opak kapanma dikdörtgeni) uygulanmıştır.


Neden sentetik veri? Gerçek veri setlerinin (SmartDoc-QA vb.) lisans/boyut değerlendirmesi henüz yapılmadığı için (bkz. `project_notes.md`, Genel Proje Planı). Sentetik veri, yer gerçeğinin (blur şiddeti, glare alanı, karartma faktörü, açı, kapanma oranı) tam olarak bilinmesini sağladığı için yöntemlerin **temel davranışını** (monotonluk, duyarlılık) doğrulamak için uygundur — ama **gerçek kamera koşullarını** (defokus+hareket karışımı, gerçek kağıt dokusu, **JPEG artefaktları**, **renkli kağıt tonu**) temsil etmez. Bu, raporun tamamında tekrarlanan temel bir sınırlamadır (bkz. Bölüm 18).

Özellik	Değer
Toplam sentetik görüntü sayısı	Blur: 108, Glare: 84 (12 orijinal + 72 degrade), Darkness: 144 (72 global + 72 lokal), Skew: 132, Occlusion: 72
Format	PNG, gri tonlamalı (8-bit)
Train/validation/test ayrımı	Yok — bu aşamada model eğitimi yapılmadı, yalnızca deterministik/analitik yöntemler test edildi
Ground truth	Her modülde algoritmik olarak (üretim parametrelerinden) kesin biçimde biliniyor

6. Proposed Architecture

Literatür + Bizim Yöntemimiz: `initial_research.md`, üç mimari alternatifi karşılaştırıp **Hibrit Mimariyi** önermiştir; bu proje bu öneriyi takip etmektedir.

Özellik	Classical CV	Hybrid (seçilen)	End-to-End DL
Veri ihtiyacı	Düşük	Orta	Yüksek
Açıklanabilirlik	Yüksek	Yüksek/Orta	Düşük
Eğitim gereksinimi	Yok	Kısmi (füzyon aşamasında)	Yüksek
Debug kolaylığı	Yüksek	Orta-Yüksek	Düşük
Bu projedeki durumu	5 modülün tamamı bu katmanda	Henüz uygulanmadı (Aşama 5)	Uygulanmadı



Beş kalite modülü bu raporda geliştirilip test edilmiştir; **feature fusion ve ML regresyon aşaması bu raporun kapsamında DEĞİLDİR** (bkz. Bölüm 13).

7. Methodology

Her modül için aynı deneysel desen izlenmiştir:

- Literatür seçimi** — o problem için literatürde önerilen baseline yöntem(ler) belirlendi (`research/literature_review.md`).
- Uygulama** — yöntem `src/<modül>/metrics.py` içinde, bağımsız test edilebilir fonksiyonlar olarak

yazıldı.

3. **Kontrollü sentetik deney** — bilinen şiddette/yer gerçeğinde bozulma enjekte edilen veri `experiments/<modül>/` altında üretildi.
4. **Monotonluk testi** — bozulma şiddeti arttıkça skorun tutarlı yönde değişip değişmediği **Spearman rank korelasyonu** ile ölçüldü.
5. **Dynamic range / etki büyüklüğü testi** — (Glare modülünde fark edilen bir yanılğı sonrası tüm modüllere eklendi) yalnızca korelasyona değil, skorun severity=0'dan severity=max'a ne kadar **pratik olarak değiştiğine** de bakıldı; yüksek korelasyon + düşük dynamic range kombinasyonu yanıltıcı olabilir (bkz. Bölüm 9, 16).
6. **Sonuçların** `project_notes.md` 'ye kaydı — problem, yöntem, gerekçe, parametreler, deney, sonuç, karşılaşılan problemler, kararlar, sonraki adım.

Tüm deney kodları çalıştırılabilir script'ler olarak `experiments/` altında saklanmıştır; hiçbir sonuç elle hesaplanmamış, tamamı kod çalıştırılarak üretilmiştir.

8. Blur Detection

Literatür: Laplacian variance en yaygın başlangıç yöntemi; tek başına threshold olarak güvenilirmez (text yoğunluğu, font, çözünürlük, noise, JPEG'den etkilenir). Tenengrad/gradient magnitude ve FFT/frekans-alanı yöntemleri de literatürde yer alıyor.

Bizim Yöntemimiz: `src/blur/metrics.py` — **Laplacian Variance** ve **Tenengrad** (Sobel gradyan büyüklüğü karesi ortalaması), artı yardımcı bir **Gradient Magnitude Mean**. Yöntemlerin çalışma prensibi: `src/blur/README.md`.

Bizim Sonuçlarımız: 12 sentetik belgeye, 9 kademeli Gaussian blur şiddeti ($\sigma = 0 \rightarrow 8$) uygulandı (108 görüntü).

Metrik	Ortalama Spearman rho (12 belge)
Laplacian Variance	−0.9986 (std 0.0048)
Tenengrad	−1.0000 (std 0.0000)

Her iki yöntem de blur şiddetiyle neredeyse mükemmel monoton azalma gösterdi.

Ek bulgu — font boyutu duyarlılığı: Blur hiç yokken bile (severity=0), yalnızca font boyutu farkı skorlarda büyük değişkenlik yarattı — **coefficient of variation:** Laplacian %27.2, Tenengrad %32.1. Bu, literatürün “tek eşik güvenilirmez” iddiasını bu sentetik veri özelinde doğrulamaktadır.

(Detay: `project_notes.md` “Modül: BLUR”; ham veri: `results/blur/`.)

9. Glare Detection

Literatür: HSV (yüksek Value + düşük Saturation) eşikleme + connected components baseline; Rodin & Orlov (2019) CNN tabanlı ileri yöntem. Literatür açıkça uyarıyor: “beyaz belge alanı da yüksek parlaklığa sahip olabilir.”

Bizim Yöntemimiz: `src/glare/metrics.py` — HSV eşikleme ($V \geq 235$, $S \leq 35$) + connected components filtreleme (min. 15px), yalnızca belgenin içerik kutusu içinde uygulandı.

Bizim Sonuçlarımız: 12 belgeye, içerik alanının %0-%22'sini kaplayan, yumuşak kenarlı sentetik glare lekeleri eklendi (72 görüntü). **Sonuç: yöntem, mevcut haliyle sentetik veride pratik olarak işe yaramamaktadır:**

Metrik	Spearman rho	Severity=0 ort.	Severity=max ort.	Göreceli değişim
naive_glare_ratio (bizim yöntemimiz)	1.0000 (yanıltıcı — bkz. altta)	0.849	0.860	%1.3
oracle_text_washout_ratio (yalnızca doğrulama)	1.0000	0.000	0.034	anlamli

amaçlı, referans gerektirir)				
------------------------------	--	--	--	--

Spearman korelasyonu her iki metrik için de mükemmel (1.0) görünse de, **naive_glare_ratio** pratikte **neredeyse hiçbir ayırt edici güce sahip değildir** — glare hiç yokken bile içerik kutusunun %84.9'unu “glare” olarak işaretlemekte, gerçek glare eklendiğinde bu oran yalnızca %86.0'a çıkmaktadır. Kök neden: sentetik belgeler gri tonlamalı olduğu için HSV'nin Saturasyon kanalı **her zaman sıfır** çıkmaktadır — yöntemin ayırt edici gücünün yarısı (S eşiği) matematiksel olarak devre dışı kalmaktadır. Bu, literatürün uyarısının en uç biçimde doğrulanmasıdır.

Sonuç: Bu modül “tamamlandı” değil, **“baseline denendi ve mevcut haliyle yetersiz bulundu”** statüsündedir.

(Detay: `project_notes.md` “Modül: GLARE”; ham veri: `results/glare/`.)

10. Darkness Detection

Literatür: Global/median brightness, histogram + percentile (P5-P95), local brightness/contrast (klasik); illumination estimation / shadow removal (ileri, Wang et al. 2025 survey). Literatürün temel iddiası: aynı global ortalamaya sahip iki görüntü farklı kalitede olabilir (biri homojen karanlık, diğeri genel aydınlık ama kritik bir alanı karanlık).

Bizim Yöntemimiz: `src/darkness/metrics.py` — global mean/median, percentile'lar (P5/P25/P50/P75/P95), ve **16×16 piksellik blok-bazlı yerel analiz** (en karanlık blok ortalaması + yerel kontrast).

Bizim Sonuçlarımız: İki senaryo test edildi (her biri 72 görüntü, 6 şiddet seviyesi):

Global karartma senaryosu: Tüm metrikler mükemmel monoton ($\rho = -1.0000$, tümü).

Lokal karartma senaryosu (yalnızca “Belge No” alanı, görüntünün ~%0.29'u karartıldı):

Metrik	Severity=0→max göreceli değişim	Spearman rho
global_mean	−%0.35 (pratikte kör)	−1.0000 (yanıltıcı)
p25, p50	%0 (sabit, hiç tepki yok)	tanımsız (varyans yok)
p5	−%4.84 (kısmi)	−0.874
darkest_block_mean (bizim önerdiğimiz)	−%55.58 (güçlü, net)	−0.828

Sonuç: Bu deney, literatürün “global ortalama yetersiz” iddiasını doğrudan doğrulamaktadır. Global mean ve medyan/P25/P50, görüntünün <%1'ini kaplayan lokal bir karanlık bölgeyi neredeyse hiç yakalayamazken, blok-bazlı yerel analiz güçlü bir tepki vermiştir. **Bu, Glare modülünün aksine, baseline yöntemin (blok-bazlı bileşeni) beklendiği gibi çalıştığı bir modüldür.**

(Detay: `project_notes.md` “Modül: DARKNESS”; ham veri: `results/darkness/`.)

11. Skew Detection

Literatür: Hough Transform ve Projection Profile, en sık kullanılan klasik yöntem aileleri (Hull, 1998; Biswas et al., 2023).

Bizim Yöntemimiz: `src/skew/metrics.py` — Hough Transform (Canny + HoughLines, yakın- yatay doğruların medyan açısı) ve Projection Profile (−15°...+15°, 0.5° adımlarla, satır profili varyansını maksimize eden açı).

Bizim Sonuçlarımız: 12 belge, 11 bilinen açıyla (−12°...+12°) döndürüldü (132 görüntü).

Yöntem	Genel MAE	Std
Hough Transform	0.82°	2.01
Projection Profile	1.82°	5.10

Genel ortalama Hough'u daha iyi gösterse de, dağılım çok farklı bir hikâye anlatıyor: **Projection Profile, 12 belgenin 10'unda MAE = 0.0000° (mükemmel)**, ama **2 belgede (en küçük font + en az paragraf, yani en az metin satırı) MAE ≈ 9.5-12.3°** ile başarısız oldu — başarısız tahminlerin tamamı arama aralığının sınırına (−15°) kilitlendi. Hough ise daha istikrarlı ama aç ı büyüdükçe kademeli olarak kötüleşti (0°'de MAE=0.21°, 12°'de MAE=1.79°).

Sonuç: İki yöntem farklı, tamamlayıcı hata modlarına sahip; ikisi arasındaki büyük anlaşmazlık ileride bir güvenilirlik sinyali olarak kullanılabilir.

(Detay: `project_notes.md` "Modül: SKEW"; ham veri: `results/skew/`.)

12. Occlusion Detection

Literatür: OCR confidence (yardımcı sinyal, tek başına yeterli değil — diğer bozulmalar da confidence'ı düşürür); object detection/segmentation (ileri yöntem, bu projede uygulanmadı). Belgeye özel, geniş kabul görmüş bir occlusion veri seti/yöntemi bu oturumda bulunamadı.

Bizim Yöntemimiz: `src/occlusion/metrics.py` — **OCR + beklenen alan deseni:** "Belge No" alanı (bilinen konum, bilinen format = 10 haneli sayı) kırılıp Tesseract ile OCR edildi; iki sinyal hesaplandı: **length_ratio** (okunan karakter sayısı / beklenen 10) ve **mean_confidence** (Tesseract'ın güven skoru), birleştirilerek **occlusion_suspicion_score** (0-100, yüksek=şüpheli) üretildi.

Bizim Sonuçlarımız: 12 belgede, "Belge No" alanı %0-%100 arasında kademeli kapatıldı (72 görüntü).

Metrik	Spearman rho	Coverage=0	Coverage=%100
length_ratio	−0.976	1.000	0.000
mean_confidence	−0.853	91.7	0.0
occlusion_suspicion_score	+0.945 (yön ters — "şüphe" skoru)	4.2	100.0

Sonuç: Üç metrik de güçlü, tutarlı monoton sinyal verdi. Bu modül, **Darkness gibi, baseline yöntemin beklendiği gibi çalıştığı** bir modüldür — ama yalnızca **konumu ve formatı bilinen, yapılandırılmış alanlar** için (serbest metin için uygulanmadı).

(Detay: `project_notes.md` "Modül: OCCLUSION"; ham veri: `results/occlusion/`.)

13. Feature Fusion and Quality Scoring

✗ **Not evaluated.** `initial_research.md`, beş alt-skorum bir ML regresyon modeliyle (Random Forest / XGBoost / SVR) tek bir 0-100 skora birleştirilmesini önermektedir (Aşama 5). Bu proje bu aşamaya **henüz ulaşmamıştır**; `src/scoring/` klasörü boş bir placeholder olarak durmaktadır. Bu aşamaya geçilmeden önce çözülmesi gereken, deneylerde tespit edilen açık noktalar Bölüm 17 ve 19'da listelenmiştir (örn. skor yönü/convention tutarsızlığı, Glare modülünün düzeltilmesi gerekliliği).

14. Experimental Setup

Özellik	Değer
Python sürümü	3.11
Ana kütüphaneler	OpenCV (headless) 4.13, NumPy 2.4, pandas 3.0, SciPy, Matplotlib, Pillow, pytesseract + Tesseract 5.3 (+ tur dil paketi)
Veri	Tamamen sentetik (bkz. Bölüm 5)
Donanım	CPU (GPU kullanılmadı — hiçbir yöntem GPU gerektirmiyor)
Rastgelelik kontrolü	Tüm sentetik veri üretiminde sabit seed (42) kullanıldı —

	sonuçlar tekrarlanabilir
Değerlendirme metrikleri	Spearman rank korelasyonu (monotonluk), Mutlak Hata/MAE (skew), dynamic range / göreceli değişim (etki büyüklüğü)

15. Results

Tüm modüllerin özet karşılaştırması (birincil monotonluk metriği):

Modül	Ana metrik	Spearman rho	Pratik duyarlılık (dynamic range)	Durum
Blur	Tenengrad	-1.0000	Yüksek (birkaç kat büyüklük değişimi)	✓ Çalışıyor
Glare	naive_glare_ratio	1.0000 (yanıltıcı)	Çok düşük (%1.3)	⚠ Yetersiz
Darkness (lokal)	darkest_block_mean	-0.828	Yüksek (%55.6)	✓ Çalışıyor
Skew	Hough	MAE 0.82°	—	✓ Çalışıyor (istikrarlı)
Skew	Projection Profile	MAE 1.82° (ortalama, aykırı değerlerden etkilenmiş)	—	⚠ Koşullu (az metinde başarısız)
Occlusion	length_ratio	-0.976	Yüksek (1.0→0.0)	✓ Çalışıyor

En önemli genel bulgu: Yalnızca Spearman korelasyonuna bakmak yanıltıcı olabilir (Glare ve kısmen Darkness/global_mean bunun kanıtı). Bir yöntemin gerçekten kullanışlı olup olmadığını anlamak için korelasyon YANINDA mutlaka **dynamic range / etki büyüklüğü** de ölçülmelidir — bu proje boyunca öğrenilen ve metodolojiye sonradan eklenen bir derstir.

16. Method Comparisons

Yalnızca gerçekten anlamlı karşılaştırmalar için tablolar:

Blur — iki yöntemin karşılaştırması:

Yöntem	Type	Training	Explainability	Hız	Sonuç (bu projede)
Laplacian Variance	Classical (2. türev)	Hayır	Yüksek	Yüksek	rho=-0.9986, font boyutuna duyarlı (CV=%27.2)
Tenengrad	Classical (1. türev)	Hayır	Yüksek	Yüksek	rho=-1.0000, font boyutuna duyarlı (CV=%32.1)
FFT/Frequency, CNN	Literatür (uygulanmadı)	—	—	—	Not evaluated

Skew — iki yöntemin karşılaştırması:

Yöntem	MAE (genel)	En iyi senaryo	En kötü senaryo
Hough Transform	0.82°	Küçük açılar (0.21-0.36°)	Büyük açılar (1.79° @ 12°)
Projection Profile	1.82°*	Yeterli metin varsa (10/12 belgede MAE=0°)	Az metinli belgelerde (2/12 belgede MAE=9.5-12.3°)

(*Ortalama, az-metin aykırı değerlerinden güçlü etkilenmiştir — bkz. Bölüm 11.)

Occlusion — iki sinyalin karşılaştırması:

Sinyal	Spearman rho	Gürültü düzeyi
length_ratio	-0.976	Düşük, düzgün eğri
mean_confidence	-0.853	Orta, özellikle orta-kapanma seviyelerinde dalgalı

Mimari karşılaştırması (initial_research.md'den, bu projede yalnızca Classical CV katmanı test edildi):

Özellik	Classical CV (bu projede test edildi)	Hybrid (planlandı, uygulanmadı)	End-to-End DL (uygulanmadı)
Veri ihtiyacı	Düşük — doğrulandı (sentetik/az veriyle çalıştı)	Orta — Not evaluated	Yüksek — Not evaluated
Açıklanabilirlik	Yüksek — doğrulandı (her skorun nedeni izlenebilir)	Yüksek/Orta — Not evaluated	Düşük — Not evaluated
Karmaşık bozulmalarda başarı	Karışık — 3/5 modülde iyi, 1/5 yetersiz (Glare), 1/5 koşullu (Skew/Projection)	Not evaluated	Not evaluated

17. Discussion

Bu projenin en değerli çıktısı, beklendiği gibi çalışan yöntemler kadar, **beklendiği gibi çalışmayan yöntemlerin neden çalışmadığının anlaşılmasıdır**:

- **Glare modülü**, literatürün “beyaz kağıt da parlak olabilir” uyarısını salt teorik bir dipnot olmaktan çıkarıp, sentetik veride %1.3'lük bir dynamic range olarak somut biçimde göstermiştir. Kök neden (gri tonlamalı sentetik veride S kanalının işlevsiz kalması) yalnızca kod yazılıp çalıştırıldığında ortaya çıkmıştır — bu, “önce basit baseline dene, sonuçları ölç” yaklaşımının değerini doğrulamaktadır.
- **Skew modülünde Projection Profile'in az-metinli belgelerde arama sınırına kilitlenmesi**, yöntemin literatürde iyi bilinen bir avantajının (metin satırı düzenine dayanması) aynı zamanda bir zayıflık kaynağı (yetersiz metin = zayıf sinyal) olabileceğini göstermiştir.
- **Darkness ve Occlusion modüllerinde**, literatürün önerdiği “tek bir global ölçüm yerine yerel/yapılandırılmış analiz” yaklaşımı beklendiği gibi çalışmış ve büyük fark yaratmıştır (darkness'ta %55.6 vs %0.35 dynamic range farkı).

Genel çıkarım: **beş modülün hiçbirisi “tak-çalıştır” düzeyinde production'a hazır değildir** — her biri, bu raporda tespit edilen en az bir açık nokta (Bölüm 18) ile birlikte değerlendirilmelidir.

18. Limitations

1. **Tüm veri sentetiktir.** Gerçek kamera görüntülerinin (defokus+motion blur karışımı, gerçek kağıt dokusu/rengi, JPEG sıkıştırma artefaktları, gerçek gölge/aydınlatma fiziği) hiçbirisi bu deneylerde temsil edilmemiştir. Tüm sayısal sonuçlar yalnızca bu sentetik veri bağlamında geçerlidir.
2. **Glare modülü mevcut haliyle kullanılamaz** (bkz. Bölüm 9) — sentetik verinin grayscale olması bunu abartmış olabilir, ama ROI'nin (içerik kutusu) satır-arası boşlukları içermesi sorunu gerçek renkli veride de (daha az şiddetli olsa da) devam edecektir.
3. **Occlusion modülü yalnızca yapılandırılmış (format bilinen) alanlar için çalışır** — serbest metin occlusion tespiti bu projede ele alınmamıştır.
4. **Feature fusion / ML skorelama yapılmamıştır** — nihai 0-100 Quality Score bu raporda YOKTUR.
5. **Skor yönü (convention) tutarsızlığı** fark edilmiş ama düzeltilmemiştir: Blur/ Darkness/Glare'de yüksek=iyi, Occlusion'ın `occlusion_suspicion_score` 'unda yüksek=kötü. Füzyon öncesi normalize edilmelidir.
6. **Font-boyutu x blok-analizi etkileşimi** (Darkness modülü) ve **font-boyutu duyarlılığı** (Blur modülü) kesin olarak açıklanmamış, yalnızca gözlemlenmiştir.
7. **Değerlendirme yalnızca sentetik/algoritmik ground truth ile yapılmıştır** — hiçbir aşamada insan değerlendirmesi (initial_research.md'nin önerdiği 0-4 skala) veya gerçek OCR doğruluğu (paragraf metinleri için) kullanılmamıştır.

19. Future Work

project_notes.md 'de her modülün kendi “Bir sonraki adım” notu vardır; genel öncelik sırası:

1. Gerçek veri setiyle (SmartDoc-QA veya benzeri) tüm modüllerin yeniden doğrulanması.
2. Glare modülünün düzeltilmesi (renkli veri, ve/veya ROI'nin metin satırı sıkı kutularına daraltılması, ve/veya Rodin & Orlov'un CNN yaklaşımının denenmesi).
3. Skor yönü normalizasyonu (tüm alt-skorlar “yüksek=iyi” yönüne çevrilmeli).
4. Ground truth stratejisinin somutlaştırılması (insan değerlendirmesi + gerçek OCR doğruluğu birleşimi).
5. Feature fusion / ML skorlama (Aşama 5) — ağırlıklı toplam ile RF/XGBoost/SVR karşılaştırması.
6. Bölüm 20'de önerilen, kimlik sahteciliğine özel ek yöntemlerin değerlendirilmesi.

20. Kimlik Sahteciliğine Özel Önerilen Yöntemler

Önemli çerçeveleme notu: Bu bölümdeki hiçbir yöntem bu projede **uygulanmamış veya test edilmemiştir** — tamamı ❌ dış araştırmaya dayanan, gerekçeli **önerilerdir**. DeneySEL bir sonuç DEĞİLDİR.

Ayrıca kavramsal bir ayrım öne çıkıyor: Bölüm 8-12'deki beş modül **“bu bir çekim kalitesi sorunu mu?”** sorusuna cevap veriyor (yani: fotoğraf iyi mi çekilmiş?). Sahtecilik ise farklı bir soru: **“bu belge/görüntü değiştirilmiş mi?”** İyi çekilmiş (bulanık olmayan, iyi aydınlatılmış) bir görüntü, mükemmel biçimde sahte olabilir; kötü çekilmiş bir görüntü tamamen gerçek olabilir. Bu yüzden kimlik sahteciliği tespiti için Bölüm 8-12'deki modüller **gerekli ama yeterli değildir** — aşağıdaki yöntemler bu boşluğu kapatmaya yöneliktir.

20.1. Neden “herkesin aklına gelmeyecek” yöntemler önemli?

Çoğu sahtekar, sahte bir kimliği **gözle görülür şekilde ikna edici** hale getirmeye odaklanır (net, doğru renkli, doğru fontlu görünmesi). Bu tür sahtecilikler genellikle görsel kalite kontrolünü (blur/glare/darkness/skew) kolayca geçer — çünkü sahtekarın amacı zaten “iyi görünmesini sağlamak”tır. Aşağıdaki yöntemler, sahtekarın **muhtemelen hiç düşünmediği veya düzeltmeyi bilmediği** dijital/matematiksel izlere odaklanır.

20.2. Öncelik sırasıyla önerilen yöntemler

1) Checksum / kontrol hanesi (check-digit) doğrulaması — en yüksek öncelik

Birçok resmi kimlik numarası formatı (örn. MRZ — Machine Readable Zone, ICAO Doc 9303 standardı), belge numarası, doğum tarihi gibi alanlarda **matematiksel bir kontrol hanesi** içerir: her karakter bir ağırlıkla (7-3-1 tekrar eden dizi) çarpılır, toplanır, mod 10 alınır ve sonuç son haneyle karşılaştırılır. Bir sahtekar tek bir haneyi değiştirdiğinde, kontrol hanesini de doğru biçimde yeniden hesaplaması gerekir — çoğu sahtekar bu algoritmanın **varlığından bile haberdar değildir**. ❌

- **Neden düşük maliyetli/yüksek etkili:** Görüntü işleme gerektirmez, saf aritmetik bir doğrulamadır — milisaniyeler sürer, false-positive riski neredeyse sıfırdır (format doğruysa kesin doğrulanır).
- **Neden “herkesin aklına gelmeyecek” bir yöntem:** Görsel olarak kusursuz sahte bir belge bile, kontrol hanesi yanlışsa anında yakalanır — sahtekarın bunu bilmesi ve doğru hesaplaması gerekir.
- Kaynak: [MRZ check digits explained](#), [ICAO 9303 MRZ check digits](#).

2) Copy-move (klon) tespiti

Sahtekarların en sık kullandığı tekniklerden biri, bir belgenin bir bölümünü (örn. bir karakter, bir arka plan deseni, bir güvenlik hologramının parçası) kopyalayıp başka bir yere yapıştırmaktır. **SIFT/ORB anahtar nokta eşleştirmesi** veya blok-tabanlı benzerlik analizi, görüntü içinde **aynı desenin birden fazla kez** (farklı konumlarda) görüldüğü bölgeleri tespit edebilir. ❌

- **Neden non-obvious:** Kopyalanan bölge gözle fark edilmeyecek kadar iyi harmanlanmış olsa bile, piksel-düzeyinde “aynılık” istatistiksel olarak tespit edilebilir.

- Kaynak: [Copy-move forgery detection: Survey, challenges and future directions, EURASIP — superpixel segmentation ile copy-move tespiti.](#)

3) Error Level Analysis (ELA) / çift JPEG sıkıştırma analizi

Bir görüntünün yalnızca bir bölümü düzenlenip tekrar kaydedildiğinde, o bölge geri kalan görüntüden **farklı bir sıkıştırma “hata seviyesi”** taşır — bu farkı ELA veya çift JPEG sıkıştırma analizi (çoğu güncel yaklaşım artık CNN tabanlı) ortaya çıkarabilir. 🌀

- **Neden non-obvious:** İnsan gözüyle görünmez; yalnızca sıkıştırma matematiğini analiz ederek ortaya çıkar.
- **Sınırlama:** Görüntü birden fazla kez yeniden sıkıştırılırsa (örn. WhatsApp/ekran görüntüsü üzerinden iletilirse) sinyal zayıflayabilir — bu yüzden tek başına değil, diğer yöntemlerle birlikte kullanılmalıdır.
- Kaynak: [Error level analysis \(ELA\) — genel açıklama, ID kartı sahteciliği için ELA+RPA uygulaması, Multi-branch network for double JPEG detection and localization \(2025\).](#)

4) Font/glyph tutarlılık analizi

Kimlik şablonlarında değişken alanlar (isim, numara, tarih) genelde **sabit bir fontla** basılır. Bir alan dijital olarak değiştirildiğinde (örn. farklı bir yazı tipi editörüyle), harflerin kenar yumuşatması (anti-aliasing), karakter aralığı (kerning) veya kalınlığı (stroke width) belgenin geri kalanından **istatistiksel olarak farklı** çıkabilir. Bu proje kapsamında geliştirdiğimiz `src/blur` (kenar/sharpness ölçümü) ve `src/darkness` (yerel kontrast) modüllerindeki teknikler, bu analiz için **doğrudan yeniden kullanılabilir bir başlangıç noktası** sunuyor — aynı sharpness/local-contrast ölçümlerini “kalite” yerine “belge-içi tutarlılık” sorusuna uygulamak. 🌀

- **Neden non-obvious:** Sahtekar tek bir alanı “iyi görünecek” şekilde değiştirebilir, ama o alanın font-istatistiklerini belgenin GERİ KALANIYLA piksel-düzeyinde birebir eşleştirmesi çok daha zordur.
- Kaynak: [DocForge-Bench: document forgery detection benchmark \(2026\).](#)

5) Ekran yeniden-çekim (screen recapture) / moiré deseni tespiti

Artan bir saldırı vektörü: sahtekar, fiziksel bir sahte belge yerine, **bir ekranda gösterilen sahte belgenin fotoğrafını** çeker (eKYC sistemlerini atlatmak için). Bu, ekranın piksel ızgarasıyla kameranın sensör ızgarası arasındaki etkileşimden kaynaklanan karakteristik **moiré (girişim) desenleri** ve renk-doku tutarsızlıkları bırakır. 🌀

- **Neden non-obvious:** Çoğu kalite/sahtecilik kontrolü yalnızca belgenin İÇERİĞİNE bakar; bu yöntem belgenin “gerçekten fiziksel bir yüzeyden mi yoksa bir ekrandan mı çekildiğine” bakar — tamamen farklı bir soru.
- Kaynak: [Screenshots, Printouts, and Recapture Attacks in eKYC, Screen recapture detection based on color-texture analysis of document boundary regions.](#)

6) PRNU sensör gürültüsü analizi — ileri seviye, opsiyonel

Her kamera sensörü, üretim kusurlarından kaynaklanan benzersiz bir gürültü deseni (“parmak izi”) üretir. Bir görüntünün bir bölümü başka bir kaynaktan (örn. başka bir fotoğraf, bir ekran görüntüsü) geliyorsa, o bölgenin PRNU deseni geri kalanla uyuşmayabilir. 🌀

- **Neden opsiyonel/ileri seviye:** Güvenilir çalışması için referans kamera gürültü profili veritabanı ve nispeten yüksek çözünürlüklü, az sıkıştırılmış görüntüler gerekir — mobil/production ortamında maliyetli ve kırılgan olabilir.
- Kaynak: [Digital Image Forensics Using Sensor Noise \(Fridrich\), Combining PRNU and noiseprint for robust device source identification.](#)

20.3. Özet öneri tablosu

Yöntem	Uygulama maliyeti	Sahtekarın atlatma zorluğu	Bu projeye ilişkisi
Checksum/check-digit doğrulama	Çok düşük (saf aritmetik)	Çok yüksek	Bağımsız, yeni bir katman
Copy-move tespiti	Orta	Yüksek	Bağımsız, yeni bir katman
ELA / çift JPEG sıkıştırma analizi	Orta	Yüksek	Bağımsız, yeni bir katman
Font/glyph tutarlılık analizi	Orta	Yüksek	Bağımsız, yeni bir katman
Ekran yeniden-çekim / moiré deseni tespiti	Orta	Yüksek	Bağımsız, yeni bir katman
PRNU sensör gürültüsü analizi	Yüksek	Yüksek	Bağımsız, yeni bir katman

ELA / çift JPEG analizi	Orta	Orta-Yüksek	Bağımsız, yeni bir katman
Font/glyph tutarlılık analizi	Orta	Yüksek	Blur/Darkness modüllerinin tekniklerinden yeniden yararlanabilir
Screen recapture / moiré tespiti	Orta-Yüksek	Yüksek (özellikle eKYC bypass'ına karşı)	Bağımsız, yeni bir katman
PRNU sensör analizi	Yüksek	Çok yüksek (ama kırılgan)	Bağımsız, ileri seviye/opsiyonel

Önerilen uygulama sırası (maliyet/etki oranına göre): (1) Checksum doğrulama → (2) Copy-move + ELA → (3) Font tutarlılığı → (4) Screen recapture/moiré → (5) PRNU (yalnızca yüksek güvenlik gereksinimi varsa).

21. Conclusion

Bu proje, beş temel belge kalitesi probleminin (blur, glare, darkness, skew, occlusion) literatürde önerilen klasik baseline yöntemlerle nasıl ölçülebileceğini, sentetik ama kontrollü deneylerle test etmiştir. Üç modül (Blur, Darkness, Occlusion) beklenen, kullanışlı sonuçlar üretmiş; bir modül (Glare) mevcut haliyle yetersiz bulunmuş; bir modül (Skew) koşullu başarı göstermiştir. Bu karışık ama **dürüst** sonuç kümesi, tek bir “her şey mükemmel çalıştı” anlatısından çok daha değerlidir — çünkü hangi yöntemlerin hangi koşullarda güvenilir olduğunu somut sayılarla ortaya koymaktadır.

Projenin nihai hedefi olan kimlik sahteciliği tespiti için, bu beş modülün **çekim kalitesi kontrolü** katmanını oluşturduğu, ama asıl sahtecilik (tamper) tespitinin Bölüm 20’de önerilen, farklı bir kategori olan adli/forensic yöntemlerle tamamlanması gerektiği sonucuna varılmıştır.

22. Appendix A — Projeyi Çalıştırma ve Kullanma Kılavuzu (Basit Anlatım)

Bu bölüm, teknik bilgisi az olan biri için de anlaşılır olacak şekilde yazılmıştır.

Proje nedir, ne işe yarar?

Bu proje, bir belge/kimlik fotoğrafının **ne kadar “iyi çekilmiş”** olduğunu otomatik olarak değerlendirmeye çalışan bir araç seti. Şu an 5 ayrı “dedektör” var: biri bulanıklığa (blur), biri parlamaya (glare), biri karanlığa (darkness), biri eğikliğe (skew), biri de bir şeyin belgenin üzerini kapatıp kapatmadığına (occlusion) bakıyor. Her dedektör kendi başına çalışıyor ve bir sayı üretiyor; henüz hepsini tek bir “genel not” (0-100 skor) haline getiren son adım yapılmadı.

Projeyi çalıştırmak için ne gerekiyor?

1. **Python 3.11** kurulu bir bilgisayar (Mac, Windows veya Linux fark etmez).
2. Terminal/komut satırı açıp proje klasörüne girmek:

```
cd document-quality-scoring
```

3. Gerekli kütüphaneleri kurmak (bir kere yapılır):

```
pip install -r requirements.txt
```

4. Occlusion (kapanma) dedektörü için ayrıca bilgisayara “Tesseract OCR” adlı bir program kurulmalı (metin okuma motoru). Mac’te: `brew install tesseract tesseract-lang`. Windows’ta: Tesseract’ın resmi kurulum dosyası indirilip kurulur (UB Mannheim tesseract installer diye aratılabilir). Linux’ta: `sudo apt-get install tesseract-ocr tesseract-ocr-tur`.

Bir dedektörü nasıl çalıştırırım? (örnek: Blur)

Her dedektörün 2-3 adımı var: önce test için sahte/örnek belgeler üretilir, sonra bu belgelere yapay olarak bozulma eklenir, sonra da dedektör bu bozuk belgeleri “okuyup” sonuç üretir.

```
python3 experiments/blur/generate_synthetic_documents.py # sahte belgeler oluştur
python3 experiments/blur/apply_degradation.py           # belgeleri bulanıklaştır
python3 experiments/blur/run_experiment.py              # ölç ve sonucu kaydet
```

Bu üç komutu çalıştırdıktan sonra `results/blur/` klasörüne bakabilirsin — orada hem sayısal tablolar (Excel’de de açılabilen `.csv` dosyaları) hem de grafikler (`.png` resim dosyaları) olacak.

Diğer dedektörler için de aynı mantık geçerli, sadece klasör adı değişiyor: `experiments/glare/`, `experiments/darkness/`, `experiments/skew/`, `experiments/occlusion/`. Her klasörün içinde hangi script’in hangi sırayla çalıştırılacağı bellidir (`generate_*.py` → varsa `apply_*.py` → `run_experiment.py`).

Kendi fotoğrafımı test edebilir miyim?

Şu anki haliyle proje, kendi ürettiği **sahte/örnek** belgeler üzerinde çalışacak şekilde kuruldu — henüz “bana bir fotoğraf ver, sana skor vereyim” şeklinde hazır bir komut satırı aracı (tool) yok. Ama alt yapı (`src/blur/metrics.py` vb. içindeki fonksiyonlar) gerçek bir görüntü dosyası üzerinde de çalışacak şekilde yazıldı. Örneğin blur skorunu kendi bir fotoğrafın için görmek istersen, üç satırlık bir Python kodu yeterli:

```
import sys, cv2
sys.path.insert(0, "src")
from blur.metrics import laplacian_variance, tenengrad

img = cv2.imread("kendi_fotografim.jpg", cv2.IMREAD_GRAYSCALE)
print("Laplacian:", laplacian_variance(img))
print("Tenengrad:", tenengrad(img))
```

Bu sana ham bir sayı verir (örn. “3421.5”) — ama bu sayının “iyi mi kötü mü” olduğunu söyleyen bir eşik/skala henüz yok (bkz. Bölüm 13, 18) — bu, projenin bir sonraki aşamasında (feature fusion) çözülecek.

Sonuçları nerede görebilirim?

- `project_notes.md` — her modül için “ne yaptık, ne bulduk, neden bu kararı aldık” günlüğü. En kolay okunan, en anlaşılır dosya budur.
- `results/<modül>/` — sayısal tablolar ve grafikler.
- `reports/final_report.md` — (bu dosya) tüm projenin özet/resmi raporu.
- `README.md` — hızlı referans, komut listesi.

Bir sonraki adımda ne olacak?

Bölüm 19 (Future Work) ve Bölüm 20’de (kimlik sahteciliğine özel öneriler) detaylandırıldığı gibi: (1) gerçek fotoğraflarla test, (2) Glare dedektörünün düzeltilmesi, (3) beş dedektörün tek bir “genel not”a birleştirilmesi, (4) sahtecilik tespiti için ek (checksum, copy-move, ELA gibi) katmanların eklenmesi.

23. References

Tam kaynakça `research/references.md` dosyasındadır. Burada, bu raporda doğrudan atıfta bulunulan kaynaklar listelenmiştir.

Ana literatür (initial_research.md’den, bu oturumda doğrulandı):

1. Alaei, A., Bui, V., Doermann, D., & Pal, U. (2023). *Document Image Quality Assessment: A Survey*. ACM Computing Surveys. DOI: 10.1145/3606692.
2. Nayef, N. et al. (2015). *SmartDoc-QA: A Dataset for Quality Assessment of Smartphone Captured Document Images*. CBDAR.
3. Rodin, D., & Orlov, N. (2019). *Fast Glare Detection in Document Images*. arXiv:1911.05189.

4. Wang, B., Li, C., Zou, W., et al. (2025). *A Comprehensive Survey on Shadow Removal from Document Images*.
5. Li, H., Zhu, F., & Qiu, J. (2019). *Towards Document Image Quality Assessment: A Text Line Based Framework*. arXiv:1906.01907.
6. Hull, J. J. (1998). *Document Image Skew Detection: Survey and Annotated Bibliography*.
7. Biswas, B., Bhattacharya, U., & Chaudhuri, B. B. (2023). *An Overview of Existing Literature on Document Skew Detection*. Malaysian Journal of Computer Science.

Bölüm 20 için dış araştırma kaynakları:

8. [MRZ check digits explained](#) — TrustDocHub.
9. [ICAO 9303 MRZ check digits — how they work](#).
10. [Copy-move forgery detection: Survey, challenges and future directions](#) — ScienceDirect.
11. [Copy-move forgery detection using superpixel segmentation and Helmert transformation](#) — EURASIP.
12. [Error level analysis \(ELA\) — genel açıklama](#) — TrustDocHub.
13. [ID card fraud detection using ELA and RPA](#) — Medium.
14. [Multi-branch network for double JPEG detection and localization \(2025\)](#) — Scientific Reports.
15. [DocForge-Bench: A Comprehensive Benchmark for Document Forgery Detection \(2026\)](#) — arXiv.
16. [Screenshots, Printouts, and Recapture Attacks in eKYC](#) — Face++.
17. [Screen recapture detection based on color-texture analysis of document boundary regions](#).
18. Fridrich, J. et al. [Digital Image Forensics Using Sensor Noise](#).
19. [Combining PRNU and noiseprint for robust and efficient device source identification](#) — EURASIP.

Bu raporda atıfta bulunulmayan, ama projeye girdi sağlayan tüm diğer kaynaklar için:

research/references.md .